

Universitatea Națională de Știință și Tehnologie POLITEHNICA
București

Facultatea de Automatică și Calculatoare,
Departamentul de Calculatoare



LUCRARE DE DIPLOMĂ

CarValuator: aplicație web pentru
evaluarea prețurilor autoturismelor
second-hand folosind web scraping și
modele de învățare automată

Conducător științific:
Popescu Cornel

Autor:
Nicula Dan-Alexandru

București, 2026

Rezumat

Această lucrare prezintă proiectarea și implementarea aplicației CarValuator, un sistem web care analizează anunțuri de vânzare pentru autoturisme second-hand și estimează dacă prețul cerut este corect, prea mic sau prea mare. Aplicația pornește de la linkuri Autovit sau mobile.de, extrage informații relevante despre vehicul, normalizează datele, aplică modele de regresie antrenate pe date colectate automat și întoarce un verdict explicabil utilizatorului.

Lucrarea descrie întregul flux tehnic: colectarea datelor prin web scraping, dificultățile generate de site-urile pe care s-a realizat scraping și mecanisme anti-automatizare, deduplicarea anunțurilor, transformarea datelor brute JSON în seturi CSV pregătite pentru învățare automată, selecția caracteristicilor folosind teste statistice și antrenarea mai multor modele de regresie. Au fost comparate modele SVR, Ridge, KNN, Random Forest, Extra Trees, Gradient Boosting și un ansamblu de votare, antrenate pe ținta logaritmică a prețului. Pe setul combinat extins folosit pentru evaluare, cel mai bun model a obținut un scor R^2 de aproximativ 0.923, iar erorile absolute medii au fost în intervalul 2696-3320 EUR, în funcție de model.

Rezultatul practic este o aplicație FastAPI cu interfață web în limba română, autentificare, istoric pe cont, afișarea anunțului, estimări pe model, medie ponderată configurabilă și recomandări de anunțuri similare. Lucrarea evidențiază atât utilitatea unei astfel de soluții pentru cumpărători, cât și limitele principale ale abordării cu Web Scraping și Machine Learning: dependența de calitatea datelor colectate, instabilitatea structurii site-urilor, acoperirea redusă pentru anumite categorii de mașini și riscul ca anunțurile foarte atipice să fie estimate mai slab.

Cuprins

Rezumat	ii
1 Introducere	1
1.1 Contextul problemei	1
1.2 Motivația proiectului	2
1.3 Obiectivele lucrării	2
1.4 Metodologie generală	3
1.5 Contribuții	3
1.6 Structura lucrării	4
2 Analiza și specificarea cerințelor	5
2.1 Profilul utilizatorilor	5
2.2 Nevoi identificate	6
2.3 Cerințe funcționale	6
2.4 Cerințe nefuncționale	6
2.5 Criterii de acceptare	6
3 Studiu de piață și abordări existente	8
3.1 Evoluția pieței second-hand	8
3.2 Autovit	8
3.3 mobile.de	9
3.4 Poziționarea soluției propuse	9
3.5 Riscuri și limite ale comparației	9
4 Fundamentare teoretică și lucrări conexe	11
4.1 Evaluarea prețurilor ca problemă de regresie	11
4.2 Modele folosite	11
4.3 Transformarea logaritmică a prețului	12
4.4 Selecția caracteristicilor	13
4.5 Metrice de evaluare	13
4.6 Web scraping și considerații etice	13
4.7 Tehnologii folosite	14
5 Colectarea și pregătirea datelor	15
5.1 Sursele de date	15
5.2 Scraping pentru Autovit	16
5.3 Scraping pentru mobile.de	16
5.4 Schema datelor brute	18
5.5 Normalizare	18
5.6 Deduplicare	18
5.7 Analiza exploratorie	19

5.8	Pregătirea pentru antrenare	19
6	Modelare și selecția caracteristicilor	22
6.1	Caracteristici derivate	22
6.2	Selecția statistică	22
6.3	Preprocesare	24
6.4	Modele candidate	24
6.5	Funcționarea modelelor folosite	24
6.6	Antrenarea pe log-preț	25
6.7	Predictia finală prin medie ponderată	25
6.8	Verdictul	26
7	Arhitectura aplicației	28
7.1	Vedere de ansamblu	28
7.2	Backend FastAPI	28
7.3	Autentificare și istoric	29
7.4	Fluxul unei predicții	30
7.5	Interfața web	30
7.6	Anunțuri similare	30
7.7	Artefacte de model și grafice	31
7.8	Configurare și deployment	31
8	Studii de caz și validare funcțională	32
8.1	Rolul studiilor de caz	32
8.2	Scenariu Autovit cu mașină comună	32
8.3	Scenariu Autovit cu mașină premium	33
8.4	Scenariu mobile.de	33
8.5	Scenariu de istoric pe cont	34
8.6	Scenariu de deployment	34
8.7	Validarea mesajelor de eroare	34
8.8	Observații din testare	35
8.9	Concluziile studiilor de caz	35
9	Evaluare experimentală	36
9.1	Configurația experimentului	36
9.2	Rezultatele modelelor	36
9.3	Analiza predicțiilor	37
9.4	Corelații și interpretabilitate	38
9.5	Testare prin aplicație	39
9.6	Comparație cu indicatorii platformelor	39
9.7	Calitatea setului de date	40
9.8	Acuratețe și utilitate practică	41
9.9	Reproductibilitate	41
10	Dificultăți, limitări și concluzii	42
10.1	Dificultăți întâlnite	42
10.2	Limitări	42
10.3	Concluzii	43
10.4	Direcții viitoare	44
10.5	Încheiere	44
A	Comenzi utile pentru reproducerea experimentelor	45
A.1	Pornirea mediului	45
A.2	Colectarea datelor	45

A.3 Pregătirea setului de date	46
A.4 Antrenarea modelelor	46
A.5 Pornirea aplicației	46
A.6 Pregătirea pentru Render	47

Listă de figuri

1.1	Fluxul general al proiectului CarValuator	3
5.1	Componenta setului de date după sursă	15
5.2	Distribuția prețurilor în setul de date	19
5.3	Prețul în funcție de kilometraj	20
5.4	Mediana prețului în funcție de anul mașinii	21
5.5	Cele mai frecvente mărci în setul de date	21
6.1	Caracteristici relevante după testele statistice	23
7.1	Arhitectura sistemului CarValuator	29
9.1	Comparație de performanță între modele	37
9.2	MAE și R^2 pentru modelele evaluate	37
9.3	Preț real față de preț estimat	38
9.4	Analiza reziduurilor pentru modelul ales	39
9.5	Matrice de corelații pentru caracteristici numerice	40

Listă de tabele

2.1	Cerințe funcționale principale	6
2.2	Cerințe nefuncționale	7
3.1	Comparație între abordări	10
5.1	Rezumatul setului combinat înainte de curățarea finală pentru antrenare	16
5.2	Câmpuri extrase din anunțuri	18
6.1	Exemple de caracteristici derivate	22
6.2	Caracteristici selectate în antrenarea finală	23
6.3	Modul de funcționare al modelelor utilizate	27
7.1	Rute principale ale aplicației	29
9.1	Performanța modelelor pe setul de test	36
9.2	Exemple de comparație între estimarea CarValuator și etichetele platformelor	40
10.1	Dificultăți și soluții aplicate	43

Notății și abrevieri

API: interfață de programare a aplicațiilor
CSV: valori separate prin virgulă
JSONL: format JSON pe linii
KNN: metoda celor mai apropiați vecini
MAE: eroare absolută medie
ML: învățare automată
RMSE: rădăcina erorii pătratice medii
SVR: regresie cu vectori suport

Capitolul 1

Introducere

1.1 Contextul problemei

Piața autoturismelor second-hand este una dintre cele mai active piețe online pentru utilizatorii obișnuiți. Decizia de cumpărare este dificilă deoarece prețul unui vehicul nu depinde doar de marcă și model, ci și de vârstă, kilometraj, motorizare, dotări, stare, istoric de service, tip de vânzător, localizare și momentul apariției anunțului. În practică, două mașini care par similare la prima vedere pot avea prețuri foarte diferite, iar un cumpărător fără experiență poate interpreta greșit o ofertă.

Dimensiunea pieței justifică nevoia unui instrument de analiză preliminară. În România, segmentul mașinilor second-hand din import a ajuns în 2024 la 344486 de unități, iar reînmatriculările interne au depășit 710000 de unități, cel mai ridicat nivel din ultimii șase ani [18]. La nivel european, analiza Joint Research Centre arată că mașinile noi reprezintă doar o parte din totalul vânzărilor anuale de autoturisme și că datele despre piața vehiculelor rulate sunt dificil de armonizat între state [23]. Acest context susține abordarea proiectului: colectarea unui snapshot propriu de anunțuri și transformarea lui într-un set de date utilizabil pentru estimare.

O ofertă prea mică poate ascunde probleme tehnice, daune nedeclarate, kilometraj modificat, documente incomplete sau chiar o tentativă de fraudă. O ofertă prea mare poate fi doar rezultatul unei așteptări nerealiste din partea vânzătorului sau al unei prezentări comerciale agresive. Între aceste extreme există un interval de preț considerat rezonabil, iar identificarea lui presupune compararea anunțului cu exemple asemănătoare din piață.

Modelele hedonice de preț, introduse în literatura economică de Rosen, tratează bunurile diferențiate ca pachete de caracteristici, iar prețul observat este rezultatul contribuției acestor caracteristici [19]. În cazul autoturismelor, această idee este naturală: puterea motorului, anul, kilometrajul și marca sunt trăsături care influențează valoarea percepută. Lucrarea de față folosește aceeași intuiție, dar într-o formă aplicată: colectează anunțuri reale, extrage caracteristicile vehiculelor și antrenează modele de regresie pentru estimarea prețului.

1.2 Motivația proiectului

Motivația proiectului CarValuator este una practică. Utilizatorul introduce un link de anunț Autovit sau mobile.de, iar aplicația răspunde cu o estimare de preț corect și cu un verdict simplu: preț corect, preț prea mic sau preț prea mare. În loc să ofere doar un număr, aplicația afișează și estimările fiecărui model, diferența procentuală față de prețul publicat, imaginea mașinii, anunțuri similare și o scurtă istorie a analizelor efectuate de contul curent.

O astfel de soluție nu înlocuiește o inspecție tehnică și nu poate garanta că un vehicul este sigur de cumpărat. Totuși, poate reduce timpul necesar unei analize preliminare. Utilizatorul nu mai compară manual zeci de anunțuri, ci primește rapid o măsură orientativă a poziționării prețului. Pentru un proiect de diplomă, această problemă este potrivită deoarece include componente diverse: colectare de date, normalizare, deduplicare, analiză statistică, regresie, interfață web, autentificare și deployment.

1.3 Obiectivele lucrării

Lucrarea are următoarele obiective principale:

- construirea unui pipeline de scraping pentru anunțuri auto publice de pe Autovit și mobile.de;
- salvarea datelor brute într-un format auditabil, JSONL, astfel încât procesarea să poată fi refăcută fără scraping repetat;
- normalizarea câmpurilor relevante pentru învățare automată, inclusiv preț, an, kilometraj, combustibil, transmisie, putere și capacitate cilindrică;
- eliminarea duplicatelor exacte și a duplicatelor probabile folosind chei derivate din caracteristicile vehiculului;
- selecția caracteristicilor semnificative folosind corelație Pearson pentru variabile numerice și teste de tip chi-pătrat cu efect Cramér pentru variabile categorice;
- antrenarea și compararea mai multor modele de regresie, inclusiv SVR, Ridge, KNN și modele bazate pe arbori;
- folosirea unei ținte logaritmice pentru preț, pentru a reduce influența disproporționată a mașinilor foarte scumpe;
- integrarea modelului într-o aplicație web în limba română, cu autentificare, istoric, sugestii similare și controale configurabile pentru verdict.

Aceste obiective urmăresc nu doar obținerea unei predicții, ci și construirea unui sistem coerent, reproductibil și utilizabil. Din acest motiv, lucrarea insistă pe deciziile de proiectare și pe limitele întâlnite, nu doar pe valorile finale ale metricilor.

1.4 Metodologie generală

Fluxul proiectului urmează ideea procesului CRISP-DM, care separă un proiect de data mining în înțelegerea problemei, înțelegerea datelor, pregătirea datelor, modelare, evaluare și implementare [21]. În contextul acestei lucrări, aceste etape au fost adaptate la contextul unei aplicații web.

În prima etapă s-a definit problema de business: utilizatorul vrea să știe dacă prețul unui anunț pare rezonabil. În a doua etapă s-au colectat date din anunțuri publice, cu atenție la limitările tehnice și etice ale scraping-ului. În a treia etapă datele au fost transformate într-un set de antrenare curat. În etapa de modelare au fost comparate mai multe regresii. În etapa de evaluare s-au urmărit RMSE, MAE și R^2 , metrici uzuale pentru regresie [20]. În ultima etapă, cel mai util flux a fost expus prin API și interfață web.

Workflow-ul aplicației este ilustrat în [Figura 1.1](#). Diagrama arată separarea dintre colectarea datelor, pregătirea setului, antrenarea modelelor și utilizarea aplicației.




Figura 1.1: Fluxul general al proiectului CarValuator

1.5 Contribuții

Contribuțiile principale ale lucrării sunt următoarele:

- un scraper funcțional pentru Autovit, cu extragere de date din pagini de căutare și pagini de detaliu;
- o integrare pentru mobile.de, cu suport pentru linkuri de detaliu, scraping experimental prin pagini SEO și documentarea problemelor de blocare întâlnite;
- un modul de normalizare care produce câmpuri consecvente pentru modelare;
- un mecanism de deduplicare care elimină atât duplicate exacte, cât și anunțuri foarte asemănătoare;
- un pipeline de antrenare cu selecție statistică a caracteristicilor și modele multiple;
- un mecanism de predicție finală bazat pe medie ponderată a modelelor, cu două strategii selectabile de utilizator;
- o aplicație web completă, cu autentificare, istoric pe cont, afișare de imagini și recomandări similare;

- pregătirea proiectului pentru deployment pe Render folosind variabile de mediu și artefacte compacte.

1.6 Structura lucrării

Capitolul 2 prezintă analiza utilizatorilor și cerințele aplicației. Capitolul 3 discută piața și abordările existente pe Autovit și mobile.de. Capitolul 4 prezintă fundamentele teoretice și lucrările relevante. Capitolul 5 descrie colectarea și pregătirea datelor. Capitolul 6 explică modelele și selecția caracteristicilor. Capitolul 7 prezintă arhitectura aplicației web. Capitolul 8 validează funcțional aplicația prin scenarii, iar Capitolul 9 discută rezultatele experimentale și graficele generate. Capitolul 10 sintetizează dificultățile întâlnite, limitele curente și direcțiile viitoare.

Capitolul 2

Analiza și specificarea cerințelor

2.1 Profilul utilizatorilor

Aplicația CarValuator este gândită pentru cumpărători care caută autoturisme second-hand online și au nevoie de o verificare rapidă a prețului. Utilizatorul tipic nu este expert auto, dar poate citi datele de bază ale unui anunț: marcă, model, an, kilometraj, motorizare și preț. Înainte de o vizionare fizică, acesta vrea să știe dacă oferta este rezonabilă în raport cu piața sau dacă merită tratată cu prudență.

Pentru definirea cerințelor a fost folosit un chestionar pilot realizat în Google Forms, adresat în principal unor studenți de la Facultatea de Automatică și Calculatoare care iau în calcul cumpărarea unei mașini second-hand. Eșantionul nu a fost tratat ca studiu statistic reprezentativ pentru întreaga piață, ci ca metodă exploratorie de produs. Scopul a fost identificarea întrebărilor reale pe care le are un cumpărător la începutul procesului de selecție.

Întrebările urmărite în formular au fost:

- ce site-uri sunt folosite cel mai des pentru căutarea unei mașini second-hand;
- cât timp petrec utilizatorii comparând manual anunțuri similare;
- ce informații îi interesează înainte de a suna vânzătorul;
- dacă un indicator de tip „preț corect / prea mic / prea mare” ar fi util;
- dacă utilizatorii ar dori să vadă și exemple de anunțuri similare, nu doar o estimare numerică;
- ce nivel de toleranță față de prețul estimat li se pare acceptabil.

Concluzia practică a acestei etape a fost că nevoia principală nu este o estimare perfectă, ci o filtrare preliminară. Utilizatorii vor să reducă rapid lista de anunțuri și să știe unde merită investit timp suplimentar. Din acest motiv, aplicația nu se limitează la afișarea unui preț estimat, ci oferă și verdict, diferență procentuală, predicții pe model și anunțuri similare.

2.2 Nevoi identificate

Din analiza utilizatorilor au rezultat patru nevoi importante. Prima este verificarea rapidă a corectitudinii prețului. Un cumpărător poate vedea zeci de anunțuri într-o singură seară, iar comparația manuală devine obositoare. A doua este detectarea ofertelor suspect de ieftine. În piața auto, un preț mult sub piață poate indica defecte, istoric neclar sau tentativă de fraudă.

A treia nevoie este explicabilitatea. Un simplu număr, de exemplu 12500 EUR, nu este suficient. Utilizatorul trebuie să vadă de ce rezultatul are sens: ce modele au estimat prețul, cât de apropiate sunt predicțiile și ce anunțuri similare există. A patra nevoie este păstrarea istoricului. Cumpărarea unei mașini presupune compararea mai multor opțiuni, iar utilizatorul are nevoie să revină la analizele anterioare.

2.3 Cerințe funcționale

Tabela 2.1: Cerințe funcționale principale

Cod	Cerință
F1	Aplicația permite crearea unui cont folosind email, username și parolă.
F2	Utilizatorul autentificat poate introduce un link Autovit sau mobile.de.
F3	Sistemul extrage automat datele relevante ale anunțului: titlu, preț, an, kilometraj, combustibil, putere, capacitate cilindrică și imagine, atunci când sunt disponibile.
F4	Sistemul estimează prețul corect folosind mai multe modele de regresie antrenate offline.
F5	Aplicația afișează verdictul: preț corect, preț prea mic sau preț prea mare.
F6	Utilizatorul poate modifica toleranța procentuală folosită pentru verdict.
F7	Utilizatorul poate alege metoda de combinare a predicțiilor modelelor.
F8	Rezultatul include anunțuri similare din baza de date colectată.
F9	Fiecare predicție reușită este salvată în istoricul contului.
F10	Utilizatorul poate șterge o analiză individuală sau întregul istoric.

2.4 Cerințe nefuncționale

2.5 Criterii de acceptare

Un flux este considerat funcțional dacă utilizatorul poate crea cont, se poate autentifica, poate analiza un link valid, poate vedea verdictul și poate regăsi analiza în istoric. Pentru partea de modelare, acceptarea nu se bazează pe o predicție perfectă pentru fiecare anunț, ci pe obținerea unor metrice rezonabile pe setul de test și pe un comportament coerent în studiile de caz.

Tabela 2.2: Cerințe nefuncționale

Cod	Cerință
NF1	Interfața trebuie să fie în limba română și să fie ușor de folosit pe desktop și mobil.
NF2	Sistemul trebuie să ofere feedback vizual în timpul analizării unui link, deoarece scraping-ul poate dura câteva secunde.
NF3	Datele brute trebuie păstrate în format auditabil, astfel încât normalizarea și antrenarea să poată fi refăcute.
NF4	Modelele și datasetul folosit pentru sugestii trebuie configurate prin variabile de mediu, pentru a permite deployment în cloud.
NF5	Parolele nu trebuie salvate în clar, iar sesiunea utilizatorului trebuie gestionată prin cookie HTTP-only.
NF6	Erorile de scraping trebuie tratate explicit, fără blocarea aplicației.

Pentru partea de deployment, acceptarea minimă este ca ruta `/health` să confirme existența modelului, datasetului de similaritate și graficelor principale.

Capitolul 3

Studiu de piață și abordări existente

3.1 Evoluția pieței second-hand

Motivația proiectului este susținută de dimensiunea și dinamica pieței auto second-hand. În România, segmentul mașinilor second-hand din import a ajuns în 2024 la 344486 de unități înmatriculate, față de 309876 în 2023 și 325062 în 2022, conform unei analize publicate pe baza datelor DG CPI [18]. Aceeași sursă indică și faptul că reînmatriculările interne au depășit 710000 de unități în 2024, cel mai ridicat nivel din ultimii șase ani. Aceste valori arată că decizia de cumpărare a unei mașini second-hand nu este o situație izolată, ci o problemă frecventă pentru cumpărătorii români.

La nivel european, literatura instituțională confirmă importanța pieței vehiculelor rulate. Un raport al Joint Research Centre arată că, în cele mai mari piețe auto din UE, mașinile noi reprezintă doar o parte din vânzările anuale totale, iar înțelegerea pieței second-hand este necesară pentru analiza flotei auto și a tranziției către vehicule mai noi sau mai eficiente [23]. Același raport evidențiază și dificultatea colectării unor date armonizate despre vehiculele rulate, ceea ce justifică folosirea unor surse publice și a unor pipeline-uri de normalizare în proiecte aplicate.

3.2 Autovit

Autovit oferă deja mecanisme de evaluare a prețului. Pagina oficială de evaluare menționează că instrumentul folosește detaliile esențiale ale vehiculului, compară mașina cu vehicule similare de pe platformă și calculează un interval de preț estimat [2]. Aceeași pagină indică peste 275000 de anunțuri utilizate pentru calcularea estimării și precizează că modelul este antrenat succesiv la fiecare două săptămâni, pentru a reflecta schimbările pieței [2].

Autovit publică și explicații mai generale despre evaluarea auto online. Într-un articol de blog, platforma menționează că sunt analizate informații despre vehicul și sunt comparate anunțuri similare publicate în ultimele 12 luni [1]. Acest detaliu este important pentru poziționarea

proiectului CarValuator: indicatorul Autovit este foarte util în interiorul platformei, dar este legat de datele și regulile platformei respective.

În anunțuri, indicatorul Autovit are rol de semnal rapid pentru cumpărător, însă aplicația CarValuator urmărește o experiență diferită. Utilizatorul introduce un link, primește predicții de la mai multe modele, poate ajusta toleranța verdictului și vede exemple similare dintr-un dataset combinat. În plus, aplicația salvează istoricul analizelor pe cont, ceea ce transformă verificarea într-un proces comparativ.

3.3 mobile.de

mobile.de include la rândul său un indicator de preț. Documentația Seller API precizează că platforma poate returna un price rating pentru un vehicul și că oferta este evaluată prin analiza unei game largi de date despre vehicul și compararea cu oferte similare [14]. Răspunsul include o etichetă, de exemplu GOOD_PRICE, iar documentația explică faptul că etichetele descriu poziția prețului față de vehicule similare.

Documentația arată și limitele calculului. Price rating-ul este disponibil pentru categoria Car, nu este disponibil pentru mașini noi, vehicule avariate sau prea vechi, iar în cazul anumitor configurații poate lipsi din cauza datelor insuficiente [14]. Pentru dealeri, mobile.de oferă și un Insights API care compară listările cu vehicule similare și expune metrici de performanță ale anunțurilor, dar accesul este limitat la parteneri din programul de date al platformei [12].

Prin urmare, mobile.de are un sistem matur de indicatori interni, dar acesta nu este complet transparent pentru un utilizator extern și nu poate fi folosit liber de o aplicație academică fără acces partener. CarValuator nu încearcă să reproducă formula internă, ci construiește un model propriu pe date colectate public și documentează explicit limitările scraping-ului.

3.4 Poziționarea soluției propuse

Soluțiile existente sunt integrate în platformele comerciale și beneficiază de acces la date interne. Acesta este un avantaj major. În același timp, ele sunt orientate către propria platformă și nu oferă utilizatorului control asupra pragului de verdict sau asupra metodei de combinare a modelelor.

CarValuator este poziționat ca prototip academic independent. El nu concurează direct cu modelele comerciale, ci demonstrează un flux complet: colectare de date, normalizare, selecție statistică, antrenare ML, aplicație web, autentificare, istoric și deployment. Diferențele principale sunt sintetizate în [Tabelul 3.1](#).

3.5 Riscuri și limite ale comparației

Comparația cu Autovit și mobile.de trebuie interpretată cu prudență. Platformele comerciale folosesc probabil date interne mai bogate, inclusiv semnale care nu sunt disponibile prin scraping public. De asemenea, indicatorii lor pot fi calculați numai pentru anunțuri care respectă anumite

Tabela 3.1: Comparație între abordări

Criteriu	Autovit	mobile.de	CarValuator
Sursă date	Date interne Autovit	Date interne mobile.de	Date publice colectate prin scraping
Domeniu	Platforma Autovit	Platforma mobile.de	Linkuri Autovit și mobile.de
Metodă publicată	Comparație cu anunțuri similare și model reantrenat periodic	Comparație cu oferte similare și price rating API	Modele ML antrenate local, cu metrici și grafice
Control utilizator	Limitat	Limitat	Toleranță și metodă de ponderare configurabile
Transparență în aplicație	Indicator scurt	Indicator scurt	Predictii individuale, medie ponderată, anunțuri similare

condiții de recență, stare și completitudine. În schimb, CarValuator lucrează cu un snapshot academic și cu date parțial incomplete.

Acest lucru nu invalidează proiectul, ci îi definește scopul. Lucrarea nu afirmă că prototipul depășește sistemele comerciale, ci că un flux reproductibil de scraping și machine learning poate oferi utilizatorului o verificare suplimentară, explicabilă și independentă de o singură platformă.

Capitolul 4

Fundamentare teoretică și lucrări conexe

4.1 Evaluarea prețurilor ca problemă de regresie

Estimarea prețului unui autoturism second-hand poate fi formulată ca o problemă de regresie supravegheată. Pentru fiecare anunț există un vector de caracteristici x , format din informații precum anul, kilometrajul, puterea, combustibilul și marca, și o valoare țintă y , reprezentată de prețul publicat. Scopul modelului este să aproximeze o funcție $f(x)$ care produce o estimare apropiată de y .

Această formulare este inspirată de teoria prețurilor hedonice, unde prețul unui bun diferențiat este explicat prin caracteristicile sale [19]. Pentru mașini, caracteristicile tehnice și comerciale au efecte intuitive: o mașină mai nouă este, în general, mai scumpă; un kilometraj mai mare reduce valoarea; o putere mai mare poate crește prețul, dar numai în combinație cu marca, segmentul și vechimea.

Regresia nu poate captura toate elementele care influențează valoarea reală. Starea caroseriei, istoricul accidentelor, calitatea reparațiilor, numărul de proprietari, dotările exacte sau încrederea în vânzător sunt informații greu de extras automat. De aceea, predicția trebuie interpretată ca estimare statistică, nu ca expertiză tehnică.

4.2 Modele folosite

Proiectul compară mai multe familii de modele. Alegerea nu urmărește doar obținerea celui mai bun scor, ci și observarea comportamentului modelelor pe date tabulare reale, incomplete și neuniforme.

SVR, sau Support Vector Regression, este o extensie a mașinilor cu vectori suport pentru probleme de regresie. Modelul caută o funcție cât mai plată care tolerează erori mici în interiorul

unui tub definit de parametrul ϵ , penalizând abaterile mai mari [22]. În proiect a fost folosit un kernel RBF, util atunci când relația dintre caracteristici și preț este neliniară.

Ridge Regression este o regresie liniară regularizată. Ea oferă un reper simplu și stabil, mai ales când datele conțin multe variabile categorice transformate prin one-hot encoding. Chiar dacă relația reală este neliniară, Ridge poate funcționa surprinzător de bine atunci când există suficiente caracteristici explicative.

KNN Regression estimează prețul prin vecinii cei mai apropiați ai anunțului analizat. Pentru date auto, ideea este intuitivă: o mașină ar trebui comparată cu mașini asemănătoare. Totuși, KNN este sensibil la scalare, la variabile categorice rare și la densitatea datelor în vecinătatea unui exemplu.

Random Forest construiește un ansamblu de arbori de decizie antrenati pe eșantioane diferite și pe subseturi ale caracteristicilor [3]. Acest model este robust la neliniarități și interacțiuni, dar poate produce modele mari și poate extrapola slab pentru exemple mult diferite de setul de antrenare.

Extra Trees introduce o randomizare mai puternică în alegerea pragurilor de împărțire, reducând varianța și crescând diversitatea arborilor [8]. Gradient Boosting construiește arbori secvențial, fiecare încercând să corecteze erorile rundei precedente [7]. În final, Voting Regressor combină estimările mai multor modele, încercând să reducă dependența de o singură ipoteză.

4.3 Transformarea logaritmică a prețului

Prețurile autoturismelor sunt distribuite asimetric. Majoritatea anunțurilor se află în zona medie a pieței, în timp ce un număr mic de vehicule premium sau foarte noi au prețuri mult mai mari. Dacă modelul este antrenat direct pe preț, exemplele scumpe pot domina funcția de eroare.

Pentru a reduce această problemă, pipeline-ul folosește ținta:

$$y_{log} = \log(1 + y)$$

După predicție, valoarea este readusă în EUR folosind:

$$\hat{y} = \exp(\hat{y}_{log}) - 1$$

Această transformare are două avantaje. În primul rând, comprimă intervalul valorilor și face erorile relative mai echilibrate. În al doilea rând, reduce tendința modelelor de a supraestima mașinile ieftine sau de a subestima exagerat mașinile foarte scumpe. În evaluarea proiectului, antrenarea pe log-preț a produs predicții mai stabile decât primele încercări pe preț brut.

4.4 Selecția caracteristicilor

Seturile de date obținute prin scraping conțin multe câmpuri, însă nu toate sunt utile pentru predicție. Unele câmpuri lipsesc frecvent, altele sunt prea specifice, iar altele au legătură slabă cu prețul. Pentru a evita introducerea de zgomot, pipeline-ul aplică o selecție de caracteristici înainte de modelare.

Pentru variabile numerice se folosește corelația Pearson, o măsură clasică a asocierii liniare dintre două variabile [15]. Pentru variabile categorice, ținta numerică este discretizată în intervale, apoi se aplică un test de tip chi-pătrat. Mărimea efectului este aproximată prin Cramér V, o măsură potrivită pentru tabele de contingență [4].

Selecția nu este tratată ca adevăr absolut. De exemplu, transmisia și tipul de caroserie sunt caracteristici importante în lumea reală, dar în setul combinat disponibil ele apar foarte rar pentru Autovit. Dacă o coloană are puține valori completate, testul statistic poate decide eliminarea ei nu pentru că este irelevantă conceptual, ci pentru că datele curente nu permit estimarea efectului.

4.5 Metrice de evaluare

Pentru evaluare sunt folosite trei metrice. RMSE penalizează mai mult erorile mari, fiind util pentru a observa cazurile în care modelul ratează puternic. MAE măsoară eroarea absolută medie și este mai ușor de interpretat în EUR. R^2 exprimă proporția variației țintei explicată de model, comparativ cu o predicție constantă bazată pe medie [20].

În contextul aplicației, MAE este deosebit de importantă deoarece utilizatorul gândește în diferențe concrete de bani. O eroare de 3000 EUR poate fi acceptabilă pentru o mașină de 80000 EUR, dar foarte mare pentru una de 7000 EUR. Din acest motiv, verdictul final folosește și un prag procentual configurabil de utilizator.

4.6 Web scraping și considerații etice

Web scraping-ul permite colectarea automată a datelor publicate pe pagini web, însă ridică probleme tehnice, legale și etice. Krotov și Silva subliniază că cercetătorii trebuie să analizeze scopul colectării, tipul datelor, impactul asupra site-ului și riscurile de confidențialitate [10].

În proiectul CarValuator, datele au fost folosite în scop academic, iar colectarea a fost limitată la câmpuri publice din anunțuri. Informațiile de contact nu sunt necesare pentru modelare și nu sunt folosite pentru predicție. Scraping-ul a fost rulat cu întârzieri între cereri, iar pipeline-ul păstrează datele brute tocmai pentru a evita repetarea inutilă a solicitărilor către site-uri.

Totuși, există o diferență importantă între un prototip local și un serviciu public. Dacă aplicația este publicată în cloud, fiecare predicție live poate genera o cerere server-side către site-ul anunțului. Acest lucru poate duce la limitări sau blocări, mai ales pentru mobile.de, unde mecanismele anti-automatizare sunt mai agresive.

4.7 Tehnologii folosite

Implementarea folosește Python și scikit-learn pentru pipeline-ul ML. scikit-learn este o bibliotecă standard pentru învățare automată în Python, cu implementări mature pentru regresie, preprocesare și evaluare [16]. Pentru aplicația web, backend-ul este construit cu FastAPI, un framework modern bazat pe tipuri Python și OpenAPI [6]. Pentru cazurile în care este necesară interacțiunea cu pagini dinamice, proiectul folosește Playwright, care oferă automatizare de browser pentru Python [11].

Pentru deployment a fost pregătită o configurație Render, deoarece serviciile web Render pot porni aplicații Python care se leagă la portul furnizat prin variabila de mediu PORT [17]. Template-ul LaTeX al lucrării provine din repository-ul public `cs-pub-ro/templates` [5].

Capitolul 5

Colectarea și pregătirea datelor

5.1 Sursele de date

Datele proiectului provin din anunțuri publice de pe Autovit și mobile.de. Alegerea acestor două surse are o justificare practică. Autovit este relevant pentru piața românească, iar mobile.de este una dintre platformele europene importante pentru autoturisme second-hand, inclusiv pentru cumpărătorii români care caută mașini din Germania.

Setul combinat folosit pentru evaluarea finală conține 9633 de rânduri păstrate după normalizare și deduplicare. Din acestea, 7057 provin din Autovit, iar 2576 din mobile.de. Creșterea volumului mobile.de a fost obținută printr-o metodă experimentală bazată pe pagini SEO convertite în Markdown, descrisă în secțiunea dedicată acestei surse.

Figura 5.1 prezintă distribuția surselor. Setul rămâne dominat de Autovit, dar ponderea mobile.de este suficient de mare pentru a contribui vizibil la distribuțiile de preț și la antrenarea finală.




Figura 5.1: Componenta setului de date după sursă

Tabela 5.1: Rezumatul setului combinat înainte de curățarea finală pentru antrenare

Indicator	Valoare
Rânduri încărcate	10137
Rânduri păstrate după deduplicare	9633
Duplicate exacte eliminate	291
Duplicate fuzzy eliminate	213
Rânduri fără preț	9
Mărci distincte	82
Modele distincte	693
Mediană preț brut	16640 EUR
Mediană kilometraj brut	112927 km

5.2 Scraping pentru Autovit

Pentru Autovit, scraperul a fost construit pornind de la paginile de căutare. Fiecare pagină conține mai multe anunțuri, iar structura HTML include informații suficiente pentru extragerea linkului, titlului, prețului, anului, kilometrajului și câtorva câmpuri tehnice. În unele cazuri, datele sunt disponibile și în structuri JSON incluse în pagină, ceea ce permite o extragere mai stabilă decât parsarea textului vizibil.

Fluxul de scraping salvează fiecare anunț ca obiect JSONL. Alegerea JSONL este intenționată: fiecare linie este un document independent, iar fișierul poate fi procesat incremental. Dacă scraping-ul se oprește la pagina 80 din 150, datele deja salvate rămân valide. În plus, JSONL păstrează și câmpul `raw`, unde pot fi arhivate detalii specifice site-ului. Această decizie a fost utilă atunci când unele câmpuri au trebuit reinterpretate fără a reporni colectarea.

În practică, Autovit a ridicat mai multe dificultăți. Prima dificultate a fost instabilitatea structurii paginilor. Numele claselor HTML și poziția câmpurilor se pot modifica fără avertisment, iar scraperul trebuie să fie tolerant la câmpuri lipsă. A doua dificultate a fost deduplicarea. Anunțurile promovate sau republicate pot apărea pe mai multe pagini, iar identificatorul de listing nu este întotdeauna suficient pentru eliminarea tuturor cazurilor similare. A treia dificultate a fost legată de imagini. Unele imagini sunt încărcate lazy, iar alte imagini pot reprezenta elemente de dealer, nu mașina propriu-zisă.

5.3 Scraping pentru mobile.de

Integrarea mobile.de a fost mai dificilă decât integrarea Autovit. Site-ul are localizare pe mai multe limbi, pagini dinamice, protecții anti-bot și comportament diferit între paginile de căutare și paginile de detaliu. În multe încercări, cererile automate au returnat erori 401, 403 sau 429. Aceste coduri indică lipsă de autorizare, interdicție de acces sau limitare de rată.

Pentru a crește șansele de colectare, scraperul mobile.de încearcă să folosească endpoint-uri JSON cu headere de browser. În plus, există un fallback cu Playwright, util atunci când pagina trebuie randată într-un browser real. Totuși, fallback-ul nu garantează succesul, deoarece protecțiile pot detecta mediile automate sau pot afișa pagini de consimțământ și acces

restricționat.

O problemă importantă a apărut și la imaginile anunțurilor mobile.de. Inițial, aplicația putea afișa imaginea greșită, de exemplu bannerul dealerului sau fotografia de showroom, nu fotografia principală a mașinii. Soluția a fost prioritizarea imaginilor din galeria anunțului și filtrarea surselor care par logo-uri sau imagini de dealer. Această problemă arată că scraping-ul nu înseamnă doar extragerea unui câmp, ci și interpretarea corectă a contextului în care apare acel câmp.

Din cauza acestor dificultăți, primele date mobile.de colectate au fost puține. Integrarea a rămas însă valoroasă pentru aplicație deoarece permite analiza unor linkuri de detaliu și expune limitele reale ale unui sistem care depinde de site-uri externe.

Într-o etapă ulterioară, am testat și o strategie alternativă pentru mărirea volumului de date mobile.de. API-ul oficial de căutare mobile.de există, dar accesul la anunțuri necesită autentificare Basic și un cont cu drepturi pentru serviciul respectiv [13]. Fără aceste credențiale, endpoint-ul de căutare a răspuns cu 401, în timp ce endpoint-urile publice de referință au returnat doar liste de mărci și categorii, nu anunțuri concrete.

Metoda care a funcționat practic a fost citirea paginilor SEO publice de forma <https://www.mobile.de/en/car/marca/model> printr-un serviciu de conversie HTML în Markdown, Jina Reader [9]. În loc să controleze un browser, scriptul descarcă reprezentarea Markdown a paginii, apoi parsează cardurile de anunțuri. Din fiecare card se pot extrage titlul, prețul, anul primei înmatriculări, kilometrajul, puterea, combustibilul, orașul și prima imagine. Pentru cilindree, cardurile nu oferă mereu un câmp separat, astfel că parserul folosește o regulă conservatoare din titlu, de exemplu 2.0 TDI, 1.6 HDI sau 1.5 TSI. Regula evită codurile comerciale precum 35 TFSI și expresiile de consum precum 5,5 l/100km. Pentru că aceste carduri nu expun întotdeauna ID-ul real al anunțului, scriptul generează un identificator sintetic pe baza unei amprente formate din titlu, marcă, model, an, kilometraj, putere, preț și oraș.

Prin această metodă au fost citite 118 pagini de marcă sau model și au fost obținute 2735 rânduri brute mobile.de, după filtrarea blocurilor care nu reprezentau anunțuri. După exportul prin pipeline-ul de normalizare și deduplicare fuzzy au rămas 2534 rânduri curate din metoda Markdown. Combinarea cu lotul mobile.de obținut anterior a produs 2576 rânduri curate. În acest set mobile.de combinat, puterea este disponibilă pentru 2533 rânduri, iar capacitatea cilindrică pentru 647 rânduri. Această metodă nu înlocuiește API-ul oficial și nu este ideală pentru producție, deoarece depinde de un serviciu intermediar și nu oferă toate câmpurile tehnice, precum transmisia sau caroseria. Totuși, pentru un prototip academic, ea oferă un snapshot suplimentar util și reproductibil, salvat local în JSONL și CSV.

Pentru ca aceste rânduri să fie folosite la antrenare, filtrarea finală a fost ajustată. Valorile numerice imposibile sunt eliminate în continuare, însă câmpurile tehnice lipsă, precum capacitatea cilindrică, nu mai duc automat la eliminarea rândului. Ele sunt imputate ulterior de pipeline-ul de preprocesare. Această schimbare este importantă deoarece paginile Markdown oferă preț, an, kilometraj și putere, dar nu întotdeauna detalii complete despre motor.

5.4 Schema datelor brute

Fiecare rând brut conține câmpuri comune și câmpuri specifice sursei. Câmpurile comune sunt folosite ulterior pentru normalizare și modelare. [Tabelul 5.2](#) prezintă câteva exemple.

Tabela 5.2: Câmpuri extrase din anunțuri

Câmp	Rol
source	Platforma de proveniență, de exemplu autovit sau mobilede
listing_id	Identificatorul anunțului, atunci când poate fi extras
url	Linkul original al anunțului
title	Titlul afișat în anunț
make, model, version	Marca, modelul și versiunea vehiculului
year, mileage_km	Anul și kilometrajul
price_eur	Prețul convertit sau standardizat în EUR
fuel_type, transmission	Câmpuri tehnice categorice
power_hp, engine_capacity_cm3	Putere și capacitate cilindrică
seller_type, location_city	Context comercial și geografic

5.5 Normalizare

Datele brute sunt utile pentru audit, dar nu pot fi folosite direct în modele. Prețurile pot fi scrise cu separatori diferiți, kilometrajul poate conține text, combustibilul poate avea variante lingvistice, iar unele câmpuri pot lipsi. Normalizarea transformă aceste reprezentări într-un format comun.

Prețul este convertit în `price_eur`. În datele curente, majoritatea anunțurilor sunt deja în EUR, dar câmpul păstrează explicit moneda originală pentru extensii viitoare. Kilometrajul este extras ca număr întreg în kilometri. Puterea este standardizată în cai putere, iar capacitatea cilindrică în centimetri cubi. Pentru combustibil, valorile sunt mapate în categorii precum `diesel`, `petrol`, `hybrid`, `plug_in_hybrid` și `electric`.

Normalizarea construiește și câmpuri auxiliare. `dedupe_exact_key` identifică duplicatele cu același ID de sursă. `dedupe_fuzzy_key` combină marca, modelul, anul, kilometrajul, prețul și vânzătorul într-o amprentă conservatoare. `completeness_score` numără câte câmpuri relevante sunt prezente, fiind util pentru filtrarea rândurilor slabe.

5.6 Deduplicare

Deduplicarea are două niveluri. Primul nivel elimină duplicate exacte, folosind cheia de sursă și identificatorul anunțului. Al doilea nivel elimină duplicate probabile. Acesta este necesar deoarece același vehicul poate apărea cu identificatori diferiți sau poate fi republicat.

Cheia fuzzy este construită astfel încât să fie conservatoare. Dacă două anunțuri au aceeași marcă, același model, același an, kilometraj foarte asemănător, preț foarte asemănător și același vânzător sau oraș, este probabil să fie același vehicul. În setul combinat extins, acest pas a

eliminat 213 rânduri suplimentare după eliminarea duplicatelor exacte. Numărul a crescut față de experimentul inițial deoarece paginile SEO mobile.de pot afișa același anunț în mai multe pagini de marcă sau model.

5.7 Analiza exploratorie

Analiza exploratorie arată că datele sunt neuniforme. Distribuția prețurilor este asimetrică, cu multe anunțuri în zona 5000-25000 EUR și câteva vehicule premium cu valori mult mai mari.

Figura 5.2 ilustrează această distribuție.




Figura 5.2: Distribuția prețurilor în setul de date

Kilometrajul și prețul au o relație negativă, dar relația nu este perfectă. Mașinile noi cu kilometraj mic sunt mai scumpe, însă marca și segmentul pot schimba semnificativ poziția unui anunț. O mașină premium cu kilometraj mare poate rămâne mai scumpă decât o mașină de oraș cu kilometraj mic. Figura 5.3 arată această relație.

Figura 5.4 arată evoluția medianei prețului în funcție de anul mașinii. Tendința generală este crescătoare pentru mașinile mai noi, dar există variații cauzate de compoziția pe mărci și modele.

Cele mai frecvente mărci sunt prezentate în Figura 5.5. Distribuția confirmă faptul că setul de date reflectă preferințele pieței locale, cu mărci comune în România și Europa.

5.8 Pregătirea pentru antrenare

Setul final pentru antrenare nu include toate rândurile normalizate. Înainte de împărțirea train-test, pipeline-ul elimină exemple cu prețuri nerealiste, ani foarte vechi sau viitori nejustificați și valori tehnice extreme. Pentru antrenarea finală pe setul extins, raportul indică 9367 rânduri curate, dintre care 7493 au fost folosite la antrenare și 1874 la testare.




Figura 5.3: Prețul în funcție de kilometraj

Caracteristicile candidate includ marca, modelul, combinația marcă-model, versiunea, anul, vârsta vehiculului, luna și anul primei înmatriculări, kilometrajul, kilometrajul pe an, combustibilul, transmisia, caroseria, puterea, capacitatea cilindrică, raportul cai putere pe litru, tipul vânzătorului și localizarea. Nu toate aceste caracteristici sunt păstrate. Selecția statistică este discutată în capitolul următor.




Figura 5.4: Mediana prețului în funcție de anul mașinii




Figura 5.5: Cele mai frecvente mărci în setul de date

Capitolul 6

Modelare și selecția caracteristicilor

6.1 Caracteristici derivate

Modelele nu folosesc doar câmpurile extrase direct din anunțuri. Pipeline-ul construiește și caracteristici derivate care surprind relații mai utile pentru predicție. Vârsta vehiculului este calculată ca diferență între anul curent și anul mașinii. Kilometrajul pe an împarte kilometrajul total la vârsta vehiculului, evitând interpretarea identică a două mașini cu același kilometraj, dar cu vârste diferite. Raportul cai putere pe litru este calculat din putere și capacitate cilindrică, oferind un indicator simplu al performanței specifice.

O caracteristică importantă este `make_model`, combinația dintre marcă și model. Aceasta ajută modelele să învețe că prețul nu depinde independent de marcă și model, ci de perechea lor. De exemplu, marca BMW are mai multe modele cu prețuri foarte diferite, iar modelul Seria 3 are altă distribuție decât X5. O reprezentare combinată reduce ambiguitatea.

Tabela 6.1: Exemple de caracteristici derivate

Caracteristică	Interpretare
<code>vehicle_age</code>	Vechimea mașinii în ani
<code>mileage_per_year</code>	Ritmul de utilizare anuală
<code>hp_per_liter</code>	Putere raportată la capacitatea cilindrică
<code>make_model</code>	Segment comercial aproximat prin marcă și model

6.2 Selecția statistică

Selecția caracteristicilor are rolul de a reduce zgomotul și de a elimina coloanele slab reprezentate. Pentru caracteristicile numerice, pipeline-ul calculează corelația Pearson față de prețul logaritmic. Pentru caracteristicile categorice, prețul este împărțit în intervale, iar asocierea dintre categorie și intervalul de preț este testată prin chi-pătrat. Mărimea efectului este exprimată printr-o valoare de tip Cramér V.

În configurația finală, pragurile au fost: $\alpha = 0.05$, corelație Pearson minimă absolută 0.05 pentru numerice și Cramér V minim 0.25 pentru categorice. Aceste praguri sunt suficient de permissive pentru a păstra semnale slabe, dar elimină câmpuri cu puține valori sau cu asocieri insuficientă.

Figura 6.1 prezintă cele mai relevante caracteristici. Printre cele păstrate se află versiunea, puterea, anul, vârsta vehiculului, combinația marcă-model, kilometrajul, capacitatea cilindrică, orașul și anul primei înmatriculări.




Figura 6.1: Caracteristici relevante după testele statistice

Tabela 6.2: Caracteristici selectate în antrenarea finală

Tip	Caracteristici
Numerice	year, vehicle_age, mileage_km, power_hp, engine_capacity_cm3
Numerice derivate	mileage_per_year, hp_per_liter
Categorice	make, model, make_model, version, seller_type, location_city
Înmatriculare	first_registration_year

Unele câmpuri au fost eliminate deși pot fi importante în realitate. `transmission` și `body_type` au fost eliminate în setul combinat deoarece erau completate pentru prea puține rânduri. `fuel_type` a avut semnificație statistică, dar efectul a fost sub pragul ales. Această situație indică o limitare a datelor, nu neapărat o lipsă de relevanță a combustibilului.

6.3 Preprocesare

Pipeline-ul folosește transformări diferite pentru variabile numerice și categorice. Variabilele numerice sunt imputate atunci când lipsesc și scalate pentru modelele sensibile la distanță, precum SVR și KNN. Variabilele categorice sunt imputate cu o valoare specială pentru lipsă și transformate prin one-hot encoding.

Această separare este importantă deoarece modelele au cerințe diferite. Arborii de decizie sunt mai puțin sensibili la scalare, dar SVR și KNN pot fi dominate de variabile cu valori mari, de exemplu kilometrajul. Prin standardizare, fiecare variabilă numerică are o contribuție comparabilă în spațiul de intrare.

6.4 Modele candidate

Au fost antrenate șapte modele:

- `svr_rbf`, un SVR cu kernel RBF;
- `ridge`, o regresie liniară regularizată;
- `knn_distance`, KNN cu ponderare după distanță;
- `random_forest`, ansamblu Random Forest;
- `extra_trees`, ansamblu Extra Trees;
- `gradient_boosting`, boosting pe arbori;
- `voting_ensemble`, ansamblu care combină mai multe modele.

Implementarea este realizată cu `scikit-learn` [16]. Fiecare model este inclus într-un pipeline care conține preprocesarea corespunzătoare. Această alegere reduce riscul de inconsistență între antrenare și predicție, deoarece aceeași transformare este aplicată și datelor din anunțurile live.

6.5 Funcționarea modelelor folosite

Modelele au fost alese astfel încât să acopere familii diferite de regresie: modele liniare, modele bazate pe vecini, modele cu vectori suport și ansambluri de arbori. [Tabelul 6.3](#) sintetizează ideea fiecărui algoritm și modul în care se interpretează în contextul evaluării unui anunț auto.

La nivel de implementare, toate modelele urmează același flux general:

```
1 date = incarca_csv()
2 X, y = separa_caracteristici_si_pret(date)
3 y_log = log1p(y)
4
5 pentru fiecare model candidat:
6     pipeline = preprocesare + model
7     pipeline.fit(X_train, y_log_train)
8     predictii = expm1(pipeline.predict(X_test))
```

```

9      calculeaza_RMSE_MAE_R2(predictii, y_test)
10
11     salveaza_modelul_cu_performanta_cea_mai_buna()
12     salveaza_metrici_grafice_si_predictii_individuale()

```

Listing 6.1: Pseudocod pentru antrenarea modelelor

Această structură comună a permis compararea corectă a modelelor. Diferența dintre ele nu stă în datele primite sau în transformările aplicate, ci în modul în care fiecare model învață relația dintre caracteristici și preț.

6.6 Antrenarea pe log-preț

Primele experimente au arătat că modelele pot produce predicții prea apropiate între anunțuri diferite, mai ales când distribuția țintei este dezechilibrată. Pentru a corecta parțial problema, modelele finale au fost antrenate pe $\log_1 p(\text{price})$. Această transformare reduce presiunea exemplorilor foarte scumpe și face ca erorile relative să conteze mai echilibrat.

În aplicație, predicțiile sunt inversate automat în EUR înainte de afișare. Utilizatorul nu vede valorile logaritmice. El vede prețul estimat, prețul anunțului și diferența procentuală.

6.7 Predicția finală prin medie ponderată

Aplicația nu este limitată la un singur model. Pentru fiecare anunț, sunt calculate predicții pentru modelele salvate în bundle. Predicția finală afișată utilizatorului este o medie ponderată:

$$\hat{p}_{final} = \frac{\sum_i w_i \hat{p}_i}{\sum_i w_i}$$

Prima strategie disponibilă, `inverse_mae`, folosește ponderi invers proporționale cu MAE-ul modelului:

$$w_i = \frac{1}{MAE_i + \varepsilon}$$

A doua strategie, `inverse_mae_with_agreement`, adaugă o penalizare pentru modelele care se abat mult de la mediana predicțiilor:

$$w_i = \frac{1}{MAE_i + \varepsilon} \cdot \exp\left(-\frac{|\hat{p}_i - \text{median}(\hat{p})|}{s}\right)$$

Această a doua strategie a fost introdusă deoarece un model poate avea performanță bună global, dar poate produce o predicție foarte diferită pentru un anunț atipic. Penalizarea de acord nu elimină modelul, dar îi reduce influența în predicția finală.

6.8 Verdictul

Verdictul compară prețul din anunț cu prețul estimat. Dacă diferența procentuală absolută este sub pragul ales de utilizator, anunțul este considerat corect. Dacă prețul publicat este mult sub estimare, verdictul devine preț prea mic, cu interpretare de ofertă potențial suspectă. Dacă prețul publicat este mult peste estimare, verdictul devine preț prea mare.

Pragul implicit este 15%, dar interfața permite modificarea lui. Această opțiune este necesară deoarece toleranța diferă în funcție de buget și categorie. Pentru o mașină ieftină, 10% poate fi o diferență importantă. Pentru o mașină premium, aceeași toleranță relativă poate corespunde unei sume mari, dar poate fi încă acceptabilă în negociere.

Tabela 6.3: Modul de funcționare al modelelor utilizate

Model	Idee de funcționare	Exemplu în proiect
SVR RBF	Caută o funcție neliniară care păstrează erorile mici într-un interval de toleranță și penalizează abaterile mari. Kernelul RBF permite relații neliniare între an, kilometraj, putere și preț.	Două mașini cu același an pot primi estimări diferite dacă distanța combinată față de exemplele de antrenare diferă mult.
Ridge	Este o regresie liniară cu regularizare. Coeficienții sunt micșorați pentru a evita supraînvățarea pe multe coloane one-hot.	O marcă sau o versiune poate avea un coeficient pozitiv, iar kilometrajul poate avea un coeficient negativ.
KNN	Estimează prețul ca medie ponderată a celor mai apropiate anunțuri din setul de antrenare. Vecinii mai apropiați primesc pondere mai mare.	Un Golf din 2018 este comparat cu alte Golf-uri apropiate ca an, kilometraj și putere.
Random Forest	Construiește mai mulți arbori de decizie pe eșantioane diferite și mediază predicțiile lor.	Un arbore poate învăța reguli pentru mașini diesel compacte, altul pentru mașini premium.
Extra Trees	Seamănă cu Random Forest, dar folosește praguri de împărțire mai randomizate, crescând diversitatea arborilor.	Ajută când datele conțin multe interacțiuni și zgomot, dar poate fi mai puțin stabil pentru zone rare.
Gradient Boosting	Construiește arbori secvențial. Fiecare arbore nou încearcă să corecteze erorile rămase de la ansamblul anterior.	Dacă modelul subestimează sistematic mașinile noi, arborii următori pot corecta parțial această zonă.
Voting Ensemble	Combină predicțiile mai multor modele pentru a reduce dependența de o singură ipoteză.	Predicția finală folosește o medie ponderată pe baza performanței și, opțional, a acordului dintre modele.

Capitolul 7

Arhitectura aplicației

7.1 Vedere de ansamblu

CarValuator este implementată ca aplicație web monolitică ușoară. Backend-ul FastAPI servește atât API-ul, cât și fișierele statice ale interfeței web. Această alegere simplifică deployment-ul, deoarece nu este necesar un server separat pentru frontend. Utilizatorul accesează aceeași aplicație pentru autentificare, introducerea linkului și vizualizarea rezultatului.

Componentele principale sunt:

- modulul de scraping, responsabil de extragerea datelor din linkuri Autovit și mobile.de;
- modulul de normalizare, care transformă datele brute în câmpuri model-ready;
- modulul de antrenare, care produce bundle-ul `best_model.joblib`, metrice și grafice;
- modulul de inferență, care aplică modelele pe un anunț live;
- API-ul FastAPI, care expune rutele de autentificare, predicție, istoric și artefacte;
- interfața web, scrisă în HTML, CSS și JavaScript;
- baza de date SQLite pentru conturi, sesiuni și istoric.

[Figura 7.1](#) prezintă arhitectura logică a aplicației. Separarea dintre date, modele, API și interfață permite rularea locală pentru dezvoltare și rularea în cloud cu aceleași variabile de mediu.

7.2 Backend FastAPI

FastAPI a fost ales deoarece permite definirea rapidă a rutelor HTTP și a schemelor de request prin modele Pydantic [6]. În proiect, endpoint-ul principal este `POST /predict`. El primește site-ul, linkul anunțului, pragul de toleranță, metoda de combinare a modelelor și numărul de anunțuri similare cerute.




Figura 7.1: Arhitectura sistemului CarValuator

Tabela 7.1: Rute principale ale aplicației

Rută	Metodă	Rol
/	GET	Servește interfața web
/health	GET	Verifică existența modelului și a datasetului
/auth/register	POST	Creează cont utilizator
/auth/login	POST	Autentifică utilizatorul
/auth/me	GET	Returnează contul curent
/auth/logout	POST	Șterge sesiunea curentă
/predict	POST	Analizează un anunț și salvează istoricul
/history	GET	Listează analizele contului
/history	DELETE	Șterge istoricul contului

Rutele verifică utilizatorul curent printr-un cookie HTTP-only. Această alegere reduce riscul ca tokenul de sesiune să fie citit direct de JavaScript. Pentru deployment HTTPS, cookie-ul poate fi marcat ca secure prin variabila de mediu `CARVALUATOR_COOKIE_SECURE`.

7.3 Autentificare și istoric

Aplicația permite crearea unui cont cu email, username și parolă. Parola nu este salvată în clar. Ea este transformată într-un hash PBKDF2 cu salt, iar baza de date stochează doar rezultatul necesar verificării. Sesiunile sunt salvate separat și au termen de expirare.

Fiecare predicție reușită este salvată în istoricul utilizatorului. Istoricul include titlul anunțului, linkul, prețul publicat, prețul estimat, verdictul și imaginea, atunci când aceasta este disponibilă. Utilizatorul poate șterge un element individual sau întregul istoric. Această funcționalitate a fost introdusă pentru a evita aglomerarea interfeței după mai multe teste.

7.4 Fluxul unei predicții

Atunci când utilizatorul introduce un link, aplicația parcurge următorii pași:

1. validează sesiunea utilizatorului;
2. identifică sursa linkului, Autovit sau mobile.de;
3. extrage detaliile anunțului folosind scraperul corespunzător;
4. normalizează câmpurile într-un rând compatibil cu modelul;
5. încarcă bundle-ul de modele din calea configurată;
6. calculează predicțiile individuale ale modelelor;
7. calculează predicția finală ponderată;
8. compară prețul publicat cu estimarea și produce verdictul;
9. caută anunțuri similare în CSV-ul configurat;
10. salvează rezultatul în istoricul contului și îl returnează către interfață.

Acest flux separă clar inferența de scraping. Dacă un anunț nu poate fi extras deoarece site-ul blochează cererea sau linkul a expirat, API-ul întoarce o eroare explicită. Dacă modelul lipsește, ruta `/health` indică problema.

7.5 Interfața web

Interfața este în limba română și urmărește să fie cât mai directă. Pagina principală prezintă mesajul „CarValuator: deal or scam?”, un câmp pentru link, controale pentru metoda de combinare și toleranță, apoi rezultatul analizei. Nu sunt afișate elemente decorative inutile. Utilizatorul vede doar funcționalitățile relevante: autentificare, link, stare de încărcare, verdict, estimări, grafice de performanță și istoricul contului.

În timpul analizei este afișată o animație de încărcare, deoarece scraping-ul live poate dura câteva secunde. Această animație este importantă pentru experiența utilizatorului: fără feedback vizual, aplicația ar părea blocată.

Interfața include mod întunecat și mod luminos. Alegerea este memorată local, iar designul folosește contraste puternice și carduri clare. Rezultatul afișează imaginea principală a anunțului, atunci când scraperul o poate identifica. Pentru mobile.de, această parte a necesitat filtrare suplimentară pentru a evita afișarea bannerelor dealerilor în locul fotografiei vehiculului.

7.6 Anunțuri similare

Sugestiile de anunțuri similare sunt calculate din CSV-ul de antrenare sau din datasetul configurat pentru similaritate. Un anunț este considerat similar dacă are aceeași marcă, același model sau caracteristici apropiate, precum an, kilometraj, putere și combustibil. Scopul nu este să producă o predicție suplimentară, ci să ofere utilizatorului exemple concrete din piață.

În practică, sugestiile sunt utile pentru verificarea intuitivă a verdictului. Dacă aplicația estimează că un preț este prea mare, utilizatorul poate vedea anunțuri similare cu prețuri mai mici. Dacă estimează că prețul este prea mic, utilizatorul poate observa că alte anunțuri comparabile sunt semnificativ mai scumpe.

7.7 Artefacte de model și grafice

Training-ul produce grafice PNG, iar API-ul le servește prin ruta `/model-artifacts/{filename}`. Interfața afișează cel puțin graficul de performanță pe modele și graficul preț real față de preț estimat. Aceste grafice nu sunt necesare pentru un cumpărător grăbit, dar sunt utile pentru transparență și pentru demonstrația academică.

7.8 Configurare și deployment

Aplicația este configurabilă prin variabile de mediu. Cele mai importante sunt:

- `CARVALUATOR_MODEL_BUNDLE`, calea către bundle-ul de modele;
- `CARVALUATOR_SIMILARITY_CSV`, calea către datasetul de anunțuri similare;
- `CARVALUATOR_AUTH_DB`, calea către baza SQLite pentru conturi și istoric;
- `CARVALUATOR_API_HOST` și `CARVALUATOR_API_PORT`, folosite la rularea locală.

În cloud, aplicația citește variabila `PORT`, conform practicilor platformelor precum Render [17].

Pentru Render a fost adăugat un fișier `render.yaml`. Acesta definește build command-ul, start command-ul, calea către model și calea către datasetul de similaritate. Aplicația pornește prin `python -m carvaluator_scraper.api`, se leagă la `0.0.0.0` și citește portul din variabila `PORT`, așa cum cer serviciile web Render [17]. Deoarece modelele complete pot fi foarte mari, a fost creat și un script de pregătire a artefactelor de deploy. Scriptul copiază modelul, CSV-ul și graficele într-un folder `deploy_artifacts`. În configurația curentă, artefactul comprimat `best_model.joblib` are aproximativ 204 MB, iar datasetul de similaritate este `combined_reader_20260606.csv`.

Dimensiunea modelului este o limitare practică pentru deployment prin repository Git obișnuit. Pentru o publicare stabilă, artefactele mari ar trebui gestionate prin Git LFS, un release asset, stocare externă sau printr-un build step care le descarcă dintr-un spațiu controlat. În prototip, scriptul `scripts/prepare-render-artifacts.ps1` standardizează structura locală necesară pentru deployment și reduce riscul de căi configurate greșit.

Pentru un demo gratuit, baza de date de conturi poate fi plasată în `/tmp`. Pentru un deployment persistent, este recomandat un disc persistent sau un serviciu de baze de date separat. Această distincție este importantă deoarece istoricul utilizatorilor nu trebuie pierdut într-o variantă publică stabilă.

Capitolul 8

Studii de caz și validare funcțională

8.1 Rolul studiilor de caz

Evaluarea numerică a modelelor este necesară, dar nu este suficientă pentru un proiect care trebuie folosit printr-o interfață web. Un model poate avea scoruri bune pe setul de test, dar aplicația poate eșua dacă nu extrage corect linkul, dacă afișează imaginea gresită, dacă pierde sesiunea utilizatorului sau dacă istoricul devine greu de folosit. Din acest motiv, proiectul a fost validat și prin scenarii funcționale.

Studiile de caz urmăresc comportamentul complet al aplicației, de la introducerea linkului până la salvarea rezultatului în cont. Ele nu sunt prezentate ca benchmark statistic, ci ca verificare a experienței reale. Pentru un cumpărător, aplicația contează doar dacă răspunde rapid, afișează informații inteligibile și nu ascunde situațiile în care predicția este incertă.

8.2 Scenariu Autovit cu mașină comună

Primul scenariu folosește un anunț Autovit pentru o mașină comună, de exemplu un model compact sau de clasă medie, cu an și kilometraj tipice pentru piața românească. În acest caz, aplicația are cele mai bune șanse să producă o estimare utilă, deoarece setul de antrenare conține multe exemple asemănătoare.

Fluxul observat este următorul. Utilizatorul se autentifică, introduce linkul, alege metoda implicită `inverse_mae_with_agreement` și păstrează toleranța de 15%. Interfața afișează animația de încărcare, backend-ul extrage pagina, normalizează câmpurile, încarcă modelul și returnează rezultatul. Cardul rezultatului conține titlul, prețul publicat, prețul estimat, verdictul și diferența procentuală.

Pentru mașini comune, lista de anunțuri similare este de obicei relevantă. Aplicația găsește mașini cu aceeași marcă și același model, apoi prioritizează valori apropiate pentru an și kilometraj. Acest lucru este important deoarece utilizatorul poate verifica vizual dacă verdictul este plauzibil. Dacă prețul estimat este 12000 EUR, iar anunțurile similare sunt între 11000 și

13000 EUR, verdictul „preț corect” este ușor de înțeles.

În acest scenariu, toate componentele au rol vizibil. Modelul produce estimarea, dar sugestiile similare oferă context. Imaginea anunțului confirmă că linkul a fost interpretat corect. Istoricul salvează analiza, astfel încât utilizatorul poate compara ulterior mai multe mașini.

8.3 Scenariu Autovit cu mașină premium

Al doilea scenariu folosește o mașină premium sau foarte scumpă. Acesta este un caz mai dificil deoarece distribuția prețurilor este asimetrică, iar exemplele premium sunt mai puține. În graficele de evaluare se observă că unele mașini scumpe sunt subestimate. Cauza nu este doar modelul, ci și faptul că prețul premium depinde de detalii pe care scraperul nu le captează complet: pachet de dotări, istoric de service, ediție limitată, stare estetică, garanție sau raritate.

Pentru acest scenariu, afișarea predicțiilor pe model este esențială. Dacă SVR, Ridge și ansamblul de votare sunt apropiate, iar arborii sunt mai departe, utilizatorul poate avea o încredere mai mare în estimarea centrală. Dacă predicțiile diferă mult, aplicația nu ar trebui interpretată ca verdict definitiv. Din acest motiv, strategia `inverse_mae_with_agreement` este utilă: modelele care se abat mult de la mediana predicțiilor primesc o pondere mai mică.

În cazul mașinilor premium, toleranța de 15% poate însemna o sumă mare. Utilizatorul poate reduce pragul la 10% dacă dorește o evaluare mai strictă. Această opțiune a fost adăugată tocmai pentru a evita un verdict rigid. O aplicație de evaluare trebuie să respecte faptul că noțiunea de „preț corect” depinde de context.

8.4 Scenariu mobile.de

Scenariul mobile.de validează integrarea cea mai fragilă. Utilizatorul introduce un link localizat, de forma `/ro/vehicule/detalii.html?id=...`. Backend-ul trebuie să extragă identificatorul anunțului și să parseze pagina de detaliu. În primele iterații, astfel de linkuri nu funcționau deoarece parserul se aștepta la forme diferite ale URL-ului.

După extindere, aplicația poate trata linkuri de detaliu mobile.de, însă succesul depinde de răspunsul site-ului. Dacă pagina returnează o eroare de acces, aplicația afișează o eroare de predicție. Dacă pagina este disponibilă, câmpurile sunt extrase și normalizate similar cu Autovit.

O problemă observată în acest scenariu a fost imaginea greșită. Pentru anumite anunțuri, prima imagine accesibilă era un banner de dealer sau o fotografie generală de showroom. În urma testării manuale, parserul a fost ajustat pentru a prefera imaginile din galeria vehiculului. Această corecție este relevantă pentru calitatea aplicației deoarece imaginea este un semnal vizual puternic: dacă imaginea este greșită, se poate crea impresia că întregul anunț a fost analizat greșit.

8.5 Scenariu de istoric pe cont

Autentificarea și istoricul au fost adăugate deoarece utilizatorii testează mai multe anunțuri într-o sesiune. Fără istoric, fiecare analiză dispare după refresh. Cu istoric, aplicația devine un instrument de lucru: utilizatorul poate compara oferte, poate reveni la o analiză și poate elimina testele irelevante.

Validarea acestui scenariu urmărește trei operații. Prima este crearea contului și autentificarea prin cookie HTTP-only. A doua este salvarea automată a unei predicții reușite. A treia este ștergerea unui element individual sau a întregului istoric. Această ultimă funcționalitate păstrează aplicația utilizabilă atunci când sunt comparate multe anunțuri într-o singură sesiune.

Din perspectivă de proiectare, istoricul este legat strict de contul curent. Un utilizator nu poate șterge sau vedea analizele altui utilizator. Această regulă este verificată în backend prin dependența de autentificare înainte de accesarea rutelor `/history`.

8.6 Scenariu de deployment

Deployment-ul a fost pregătit pentru Render. Scenariul de validare pornește de la o problemă practică: folderul `data` este ignorat de Git, dar aplicația are nevoie de model și CSV pentru a funcționa în cloud. Soluția a fost introducerea folderului `deploy_artifacts`, care conține un model comprimat, datasetul de similaritate și graficele de performanță.

Acest scenariu verifică ruta `/health`. Dacă modelul și CSV-ul există, ruta întoarce status „ok” și indică faptul că graficele pot fi servite. În testarea locală cu variabilele Render, ruta a confirmat existența modelului, a datasetului și a graficelor principale. Această verificare este importantă deoarece multe erori de deployment nu apar în cod, ci în calea fișierelor sau în variabilele de mediu.

O limitare a deployment-ului demo este baza de date de autentificare. Dacă este plasată în `/tmp`, conturile pot fi pierdute la restart. Pentru un serviciu public stabil, este necesar un disc persistent sau o bază de date externă. Lucrarea marchează această diferență explicit, pentru ca demo-ul și producția să nu fie confundate.

8.7 Validarea mesajelor de eroare

O aplicație care depinde de scraping trebuie să trateze erorile ca parte normală a fluxului. Linkurile pot expira, site-urile pot bloca cererea, modelul poate lipsi, iar datasetul de similaritate poate să nu fie configurat. În loc să se blocheze, aplicația întoarce mesaje explicite.

Pentru utilizator, cel mai frecvent mesaj este eșecul predicției din cauza conexiunii sau a site-ului țintă. Într-un astfel de caz, mesajul trebuie să indice problema fără a expune detalii inutile. Pentru dezvoltator, ruta `/health` ajută la diagnosticarea rapidă a configurării.

Această abordare este importantă pentru un proiect real. Un sistem ML integrat într-o aplicație web nu este evaluat doar prin scoruri, ci și prin robustețe operațională. Dacă aplicația explică

de ce nu poate analiza un link, utilizatorul are mai multă încredere decât într-o aplicație care eșuează tăcut.

8.8 Observații din testare

Testarea manuală a scos la iveală probleme care nu erau evidente din metricile offline. Prima problemă a fost uniformizarea predicțiilor unor modele. A doua a fost imaginea greșită pe mobile.de. A treia a fost aglomerarea istoricului. A patra a fost nevoia ca utilizatorul să aleagă metoda de combinare și toleranța.

Aceste observații arată valoarea iterațiilor cu interfața reală. Pipeline-ul ML poate părea complet într-un notebook, dar aplicația finală expune fricțiuni pe care doar utilizarea efectivă le dezvăluie. În proiectul CarValuator, fiecare observație a dus la o modificare concretă: log-preț, medie ponderată, filtrare de imagini, ștergere de istoric și controale în interfață.

8.9 Concluziile studiilor de caz

Studiile de caz confirmă că aplicația este funcțională pentru fluxul principal Autovit și utilizabilă pentru anumite linkuri mobile.de, cu limite clare. Ele confirmă și importanța separării între evaluarea modelului și evaluarea aplicației. Un scor bun nu garantează o experiență bună, iar o interfață bună nu compensează date incomplete sau blocaje ale sursei externe.

Prin aceste scenarii, proiectul a fost ajustat pentru a fi mai aproape de o aplicație reală. Nu este doar un script care prezice prețuri, ci un sistem cu utilizatori, istoric, erori, grafice, deployment și decizii explicite de proiectare.

Capitolul 9

Evaluare experimentală

9.1 Configurația experimentului

Evaluarea finală a fost realizată pe setul combinat extins `combined_reader_20260606.csv`. După curățarea finală aplicată de pipeline-ul de antrenare, au rămas 9367 exemple. Împărțirea train-test a folosit 80% pentru antrenare și 20% pentru testare, rezultând 7493 rânduri de antrenare și 1874 rânduri de test.

Toate modelele au fost antrenate pe ținta logaritmică a prețului. Predicțiile au fost convertite înapoi în EUR înainte de calcularea metricilor finale. Această alegere face rezultatele mai ușor de interpretat și permite compararea directă cu prețurile reale ale anunțurilor.

9.2 Rezultatele modelelor

[Tabelul 9.1](#) prezintă rezultatele principale. Cel mai bun rezultat global a fost obținut de ansamblul de votare, cu RMSE de 4602 EUR, MAE de 2696 EUR și $R^2 = 0.9231$. SVR RBF a rămas competitiv, cu $R^2 = 0.9158$, iar Extra Trees a obținut $R^2 = 0.9095$. Față de experimentul anterior, R^2 maxim este ușor mai mic, dar testul este mai realist deoarece include un volum mult mai mare de anunțuri mobile.de și o distribuție mai eterogenă.

Tabela 9.1: Performanța modelelor pe setul de test

Model	RMSE	MAE	R^2
Voting Ensemble	4602.16	2695.83	0.9231
SVR RBF	4816.44	2729.41	0.9158
Extra Trees	4991.76	2967.41	0.9095
Gradient Boosting	5093.28	3215.95	0.9058
Random Forest	5292.42	3175.31	0.8983
KNN Distance	5660.18	3319.93	0.8837
Ridge	5774.39	2924.75	0.8789

[Figura 9.1](#) prezintă comparația vizuală a performanței modelelor, iar [Figura 9.2](#) pune în paralel

MAE și R^2 .




Figura 9.1: Comparație de performanță între modele




Figura 9.2: MAE și R^2 pentru modelele evaluate

Rezultatele arată că ansamblul de votare oferă cea mai bună stabilitate pe setul extins. SVR RBF rămâne foarte bun, dar modelele de arbori contribuie la reducerea erorii atunci când sunt combinate cu modele sensibile la distanță. Ridge are în continuare MAE competitiv, dar R^2 mai slab, semn că relațiile din setul extins sunt mai puțin liniare decât în experimentul dominat de Autovit.

9.3 Analiza predicțiilor

Figura 9.3 arată relația dintre prețurile reale și cele estimate de modelul ales. Punctele sunt concentrate în jurul diagonalei, ceea ce indică predicții rezonabile pentru majoritatea anunțurilor. Totuși, se observă și cazuri de subestimare pentru vehicule foarte scumpe, în special modele premium sau configurații rare.




Figura 9.3: Preț real față de preț estimat

Figura 9.4 prezintă distribuția reziduurilor și reziduul în funcție de prețul real. Distribuția are centru apropiat de zero, dar cozi vizibile. Cozile reprezintă anunțuri unde modelul greșește semnificativ, de obicei din cauza informațiilor neobservate: echipări speciale, stare tehnică, istoric, raritate sau poziționare comercială atipică.

9.4 Corelații și interpretabilitate

Matricea de corelații din Figura 9.5 confirmă câteva relații așteptate. Anul și vârsta vehiculului sunt puternic legate de preț. Kilometrajul este corelat negativ cu prețul, iar puterea are corelație pozitivă. Capacitatea cilindrică și puterea sunt de asemenea legate între ele.

Interpretabilitatea este limitată de folosirea one-hot encoding și de modelele neliniare. Totuși, selecția statistică oferă un nivel de explicație înainte de antrenare. Utilizatorul final nu vede direct importanța caracteristicilor, dar aplicația îi arată anunțuri similare, ceea ce face verdictul mai ușor de verificat intuitiv.




Figura 9.4: Analiza reziduurilor pentru modelul ales

9.5 Testare prin aplicație

Testarea aplicației a inclus linkuri Autovit și mobile.de. Pentru Autovit, fluxul a fost în general stabil: linkul este analizat, imaginea principală apare corect, iar rezultatul este salvat în istoric. Pentru mobile.de, fluxul a necesitat mai multe ajustări. Anumite linkuri de detaliu nu erau recunoscute inițial deoarece forma URL-ului diferă între limbi și pagini. Ulterior, integrarea a fost extinsă pentru linkuri de tip `/ro/vehicule/detalii.html?id=...`

O observație importantă din testarea manuală a fost că unele modele produceau predicții foarte apropiate pentru mașini foarte diferite. Această problemă a fost vizibilă mai ales la SVR și KNN în primele variante de model. Cauzele posibile au fost scalarea, datele insuficiente pentru anumite zone de preț și distribuția dezechilibrată a țintei. Antrenarea pe log-preț și folosirea unui set mai mare au redus această problemă, dar nu au eliminat complet riscul pentru anunțuri extreme.

9.6 Comparație cu indicatorii platformelor

Pentru a verifica dacă rezultatele au sens practic, am comparat câteva exemple din setul de test cu etichetele disponibile în datele sursă. Etichetele platformelor au fost normalizate în trei clase: `fair`, `low` și `high`. Ele nu sunt perfect echivalente cu verdictul CarValuator, deoarece fiecare platformă folosește propriile reguli, propriile seturi de comparație și propriile praguri. Totuși, comparația este utilă ca verificare de plauzibilitate.

Exemplele arată că aplicația se comportă coerent în cazurile unde diferența este mare. Pentru Volkswagen Golf VII, prețul listat este cu aproximativ 22.7% peste estimare, deci verdictul CarValuator devine „prea mare”, în acord cu eticheta `high`. Pentru exemplele cu diferențe de aproximativ 8-10%, verdictul rămâne „preț corect” deoarece pragul implicit este 15%. Această diferență nu este o contradicție, ci rezultatul pragului configurabil: dacă utilizatorul alege 10%, unele cazuri marginale pot trece în zona „prea mic” sau „prea mare”.




Figura 9.5: Matrice de corelații pentru caracteristici numerice

Tabela 9.2: Exemple de comparație între estimarea CarValuator și etichetele platformelor

Sursă	Anunț	Listat	Estimat	Dif.	Platformă	CarValuator
Autovit	Toyota Hilux 4x4 Double Cab M/T Comfort	26250	26249	0.0%	fair	preț corect
Autovit	Audi A7 Sportback	32900	36558	-10.0%	low	preț corect
Autovit	Renault Clio V TCe Zen	9900	8998	10.0%	high	preț corect
mobile.de	Volkswagen Touareg 3.0 V6 4M.	21790	22277	-2.2%	fair	preț corect
mobile.de	BMW M135i xDrive	19980	21708	-8.0%	low	preț corect
mobile.de	Volkswagen Golf VII Variant Comfortline	12690	10342	22.7%	high	prea mare

9.7 Calitatea setului de date

Calitatea datelor este principalul factor care limitează precizia. Pentru Autovit, multe câmpuri importante lipsesc sau sunt neuniforme. De exemplu, transmisia și caroseria nu au fost suficient de complete în setul folosit. Pentru mobile.de, volumul de exemple este mult mai bun după metoda Markdown, iar puterea este extrasă pentru majoritatea rândurilor. Capacitatea cilindrică a fost recuperată parțial din titlurile care includ explicit valori precum 2.0 TDI sau 1.5 TSI, însă transmisia, caroseria și o parte din câmpurile tehnice lipsesc frecvent. În plus, datele provin din momente diferite și pot reflecta condiții temporare ale pieței.

Modelele învață prețurile publicate, nu prețurile finale de tranzacție. Această diferență este esențială. Un anunț poate avea preț negociabil, iar prețul real de vânzare poate fi mai mic. Prin urmare, CarValuator estimează corectitudinea față de piața anunțurilor, nu față de tranzacțiile

efective.

9.8 Acuratețe și utilitate practică

Un MAE de aproximativ 2700 EUR pentru cel mai bun model după această metrică este rezonabil pentru un prototip bazat pe scraping public, dar nu suficient pentru decizii financiare fără verificare suplimentară. Utilitatea aplicației este mai mare ca instrument de filtrare preliminară. Ea poate identifica rapid anunțuri care merită investigate sau anunțuri care par mult în afara pieței.

Pentru mașini comune, cu multe exemple în setul de date, estimările sunt mai credibile. Pentru mașini rare, modele premium, vehicule modificate sau anunțuri cu dotări speciale, eroarea poate crește. De aceea, interfața afișează și predicțiile individuale ale modelelor, nu doar media finală. Dacă modelele nu sunt de acord, utilizatorul poate interpreta rezultatul cu mai multă prudență.

9.9 Reproductibilitate

Fluxul experimental este reproductibil prin comenzile din [Apendicele A](#). Datele brute sunt salvate în JSONL, rapoartele de normalizare sunt salvate în JSON, iar antrenarea produce fișiere CSV cu predicțiile fiecărui model. Această structură permite refacerea graficelor și verificarea deciziilor de filtrare.

Limitarea practică este că scraping-ul live nu este perfect reproductibil. Anunțurile dispar, prețurile se schimbă, iar site-urile modifică structura paginilor. Din acest motiv, seturile JSONL salvate local sunt tratate ca snapshot-uri experimentale.

Capitolul 10

Dificultăți, limitări și concluzii

10.1 Dificultăți întâlnite

Dezvoltarea proiectului a fost mai dificilă în zona datelor decât în zona modelelor. Modelele pot fi înlocuite și comparate relativ ușor odată ce există un CSV curat. În schimb, obținerea unui set de date suficient de mare și suficient de coerent a necesitat multe iterații.

Pentru Autovit, principala dificultate a fost variabilitatea câmpurilor. Nu toate anunțurile includ aceleași date, iar unele informații sunt afișate în forme diferite. De exemplu, kilometrajul, puterea sau versiunea pot apărea ca text formatat, iar anumite câmpuri pot lipsi complet. În plus, anunțurile pot fi duplicate, promovate sau republicate.

Pentru mobile.de, dificultățile au fost mai severe. Site-ul folosește mecanisme de protecție care pot bloca accesul automat. În unele teste, cererile au returnat erori 401, 403 sau 429. În alte teste, pagina randată nu conținea datele așteptate sau afișa conținut intermediar. Integrarea linkurilor de detaliu a necesitat tratarea variantelor localizate, iar extragerea imaginii corecte a necesitat filtrarea imaginilor de dealer. O soluție experimentală care a funcționat pentru creșterea setului de date a fost citirea paginilor SEO publice printr-un format Markdown intermediar, urmată de parsare și deduplicare.

O dificultate separată a fost legată de predicțiile prea apropiate între mașini diferite. Aceasta a fost observată în testarea manuală a aplicației, când modele precum SVR sau KNN întorceau valori foarte asemănătoare pentru anunțuri cu prețuri reale mult diferite. Problema a indicat că pipeline-ul trebuia îmbunătățit prin date mai multe, transformare logaritmică, selecție de caracteristici și medie ponderată între modele.

10.2 Limitări

Prima limitare este dimensiunea și compoziția setului de date. Deși setul final are mii de anunțuri, el este încă dominat de Autovit. Pentru mobile.de, volumul a crescut semnificativ prin metoda Markdown, dar câmpurile sunt mai incomplete și nu justifică încă un model separat

Tabela 10.1: Dificultăți și soluții aplicate

Dificultate	Efect	Soluție aplicată
Structură HTML instabilă	Câmpuri lipsă sau extrase greșit	Parsare tolerantă și păstrarea datelor brute
Duplicate în pagini de căutare	Supra-reprezentarea unor anunțuri	Chei exacte și chei fuzzy
Blocări mobile.de	Dataset inițial mic și scraping nesigur	Headere de browser, fallback Playwright, snapshot prin pagini SEO Markdown
Imagini greșite mobile.de	Afișare banner dealer în locul mașinii	Prioritizarea galeriei vehiculului
Predictii prea uniforme	Verdict slab pentru mașini diferite	Log-preț, set mai mare, medie ponderată
Artefacte mari de model	Deployment greu pe GitHub și Render	Compresie joblib și folder de artefacte

de încredere. O versiune viitoare ar trebui să colecteze date mobile.de prin acces oficial la API, căutări filtrate la intervale controlate sau un mecanism manual de export dacă scraping-ul automat rămâne blocat.

A doua limitare este lipsa unor caracteristici importante. Starea tehnică, istoricul accidentelor, dotările exacte, reviziile, numărul de proprietari și starea anvelopelor nu sunt disponibile consecvent. Aceste informații pot schimba mult prețul, dar nu pot fi deduse sigur din câmpurile actuale.

A treia limitare este faptul că modelele învață din prețuri cerute, nu din prețuri tranzacționate. Dacă vânzătorii publică frecvent prețuri negociabile, modelul va învăța piața anunțurilor, nu piața tranzacțiilor reale. Această limitare nu poate fi eliminată fără acces la date de vânzare efectivă.

A patra limitare este dependența aplicației de site-uri externe. Dacă Autovit sau mobile.de schimbă structura paginii, schimbă endpoint-urile sau blochează cererile cloud, predicția din link poate eșua. Pentru o aplicație publică, ar fi necesar un fallback prin formular manual, unde utilizatorul introduce marca, modelul, anul, kilometrajul și restul caracteristicilor.

10.3 Concluzii

Lucrarea a demonstrat că o aplicație web pentru evaluarea prețurilor autoturismelor second-hand poate fi construită pornind de la date publice colectate automat. Sistemul rezultat include scraping, normalizare, deduplicare, selecție statistică de caracteristici, antrenare de modele ML și interfață web cu autentificare și istoric.

Rezultatele experimentale sunt încurajatoare. Pe setul combinat extins, cel mai bun model a obținut un scor R^2 de aproximativ 0.923, iar eroarea absolută medie a celui mai bun model după MAE a fost de aproximativ 2696 EUR. Aceste valori sunt potrivite pentru un prototip academic și pentru filtrare preliminară, dar nu justifică folosirea aplicației ca unic criteriu de

cumpărare.

Un rezultat important al proiectului este faptul că aplicația nu ascunde complexitatea modelării. Utilizatorul vede estimările mai multor modele, poate schimba metoda de combinare și poate ajusta toleranța verdictului. Această transparență este utilă deoarece piața auto este zgomotoasă, iar un singur număr poate fi înșelător.

10.4 Direcții viitoare

Prima direcție viitoare este extinderea datasetului. Pentru acuratețe mai bună, este necesară colectarea de date pe mai multe filtre: marcă, model, interval de preț, an și combustibil. O singură căutare largă produce multe duplicate și nu acoperă uniform piața. În plus, aplicația ar putea accepta și alte platforme relevante pentru România, de exemplu OLX Auto, pentru a reduce dependența de două surse și pentru a acoperi mai bine anunțurile locale.

A doua direcție este îmbunătățirea suportului mobile.de. O soluție robustă ar putea combina scraping prudent, cache local, import manual de fișiere exportate și formulare de fallback. Într-un serviciu public, dependența de scraping live trebuie redusă.

A treia direcție este adăugarea unor modele moderne de boosting, precum XGBoost, LightGBM sau CatBoost. Aceste modele sunt des folosite pentru date tabulare și ar putea îmbunătăți rezultatele, mai ales dacă datasetul crește.

A patra direcție este explicabilitatea. Aplicația ar putea afișa factorii care au influențat cel mai mult estimarea: kilometraj mare, model premium, an recent, putere mare sau lipsa unor date importante. Această funcționalitate ar ajuta utilizatorul să înțeleagă verdictul, nu doar să îl accepte.

A cincea direcție este transformarea aplicației într-un serviciu complet deployat. Configurația Render există, dar o variantă stabilă ar trebui să folosească stocare persistentă pentru conturi, cache pentru predicții, monitorizare pentru erorile de scraping și o strategie mai bună pentru artefactele mari de model, precum Git LFS sau stocare externă.

10.5 Încheiere

CarValuator arată că un proiect de data science aplicat nu se reduce la alegerea unui model. Datele, normalizarea, verificarea, interfața și limitele operaționale sunt la fel de importante. În această lucrare, provocarea centrală nu a fost doar să prezicem un preț, ci să construim un flux complet care pornește de la un link real și ajunge la o explicație utilă pentru utilizator.

Prin combinația dintre scraping, învățare automată și aplicație web, proiectul oferă o bază solidă pentru dezvoltări viitoare și pentru o demonstrație practică în cadrul lucrării de diplomă.

Anexa A

Comenzi utile pentru reproducerea experimentelor

Această anexă listează comenzile principale folosite în proiect. Ele sunt utile pentru refacerea fluxului experimental pe orice sistem cu Windows PowerShell.

A.1 Pornirea mediului

```
1 python -m venv .venv
2 .\.venv\Scripts\Activate.ps1
3 python -m pip install -e .
4 python -m playwright install chromium
```

Listing A.1: Inițializarea mediului Python

A.2 Colectarea datelor

```
1 python -m carvaluator_scraper.cli scrape-search autovit "https://www
  .autovit.ro/autoturisme" --pages 150 --delay 0.4 --output data\
  autovit_xl.jsonl
```

Listing A.2: Exemplu de scraping Autovit

```
1 python -m carvaluator_scraper.cli scrape-search mobilede "https://
  suchen.mobile.de/fahrzeuge/search.html?dam=false&isSearchRequest=
  true&ref=quickSearch&s=Car&vc=Car" --pages 5 --delay 1 --output
  data\mobilede_search.jsonl
```

Listing A.3: Exemplu de scraping mobile.de

```
1 python scripts\srape_mobilede_reader.py --output data\  
    mobilede_reader_20260606.jsonl --report data\  
    mobilede_reader_20260606_report.json --cache-dir data\  
    mobilede_reader_cache_20260606
```

Listing A.4: Scraping experimental mobile.de prin pagini Markdown

A.3 Pregătirea setului de date

```
1 python -m carvaluator_scraper.cli export-csv data\autovit_xl.jsonl  
    --output data\autovit_xl.csv --drop-fuzzy-duplicates --report  
    data\autovit_xl_export_report.json
```

Listing A.5: Export CSV pentru antrenare

```
1 python -m carvaluator_scraper.cli export-csv data\  
    mobilede_reader_20260606.jsonl --output data\  
    mobilede_reader_20260606.csv --drop-fuzzy-duplicates --report  
    data\mobilede_reader_20260606_export_report.json
```

Listing A.6: Export CSV pentru setul mobile.de colectat prin reader

```
1 python -m carvaluator_scraper.cli export-csv data\autovit_xl.jsonl  
    data\autovit_more_20260526.jsonl data\  
    mobilede_consolidated_20260606.jsonl data\  
    mobilede_reader_20260606.jsonl --output data\  
    combined_reader_20260606.csv --drop-fuzzy-duplicates --report  
    data\combined_reader_20260606_report.json
```

Listing A.7: Export CSV combinat pentru experimentul final

A.4 Antrenarea modelelor

```
1 python -m carvaluator_scraper.cli train-models data\  
    combined_reader_20260606.csv --output-dir data\  
    model_results_combined_reader_20260606_log --log-target
```

Listing A.8: Antrenare cu țintă logaritmică

A.5 Pornirea aplicației

```
1 .\scripts\start-carvaluator.ps1 -Port 8017 -Background -StopExisting
```

Listing A.9: Pornire automată cu scriptul proiectului

```
1 $env:CARVALUATOR_MODEL_BUNDLE = "data\  
   model_results_combined_reader_20260606_log\best_model.joblib"  
2 $env:CARVALUATOR_SIMILARITY_CSV = "data\combined_reader_20260606.csv"  
   "  
3 $env:CARVALUATOR_API_PORT = "8017"  
4 .\.venv\Scripts\python.exe -m carvaluator_scraper.api
```

Listing A.10: Pornirea serverului local

După pornire, aplicația rulează local la adresa `http://127.0.0.1:8017`. Ruta `/health` verifică dacă modelul, datasetul de similaritate și graficele principale sunt disponibile.

A.6 Pregătirea pentru Render

```
1 .\scripts\prepare-render-artifacts.ps1 -Clean -CompressModel
```

Listing A.11: Pregătirea artefactelor pentru deployment Render

Comanda creează folderul `deploy_artifacts`, copiază modelul `best_model.joblib`, datasetul `combined_reader_20260606.csv` și graficele generate la antrenare. Fișierul `render.yaml` folosește aceste căi:

```
1 CARVALUATOR_MODEL_BUNDLE=deploy_artifacts/model_results/best_model.  
   joblib  
2 CARVALUATOR_SIMILARITY_CSV=deploy_artifacts/datasets/  
   combined_reader_20260606.csv
```

Listing A.12: Variabile principale pentru Render

Pentru un deployment stabil, artefactele mari trebuie versionate sau livrate separat. Modelul comprimat al experimentului final are aproximativ 204 MB, ceea ce poate fi prea mult pentru un flux simplu prin GitHub fără Git LFS sau fără un mecanism extern de descărcare.

Bibliografie

- [1] Autovit.ro. Evaluare autoturism: cum calculezi valoarea corectă a mașinii tale. <https://www.autovit.ro/blog/evaluare-autoturism-cum-calculezi-valoarea-corecta-masinii-tale/>, 2022.
- [2] Autovit.ro. Evaluare auto online - calculator evaluare gratuită a mașinii. <https://www.autovit.ro/evaluarea-masinii>, 2026.
- [3] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [4] Harald Cramér. *Mathematical Methods of Statistics*. Princeton University Press, 1946.
- [5] cs-pub-ro. Latex templates repository. <https://github.com/cs-pub-ro/templates>, 2026.
- [6] FastAPI. Fastapi documentation. <https://fastapi.tiangolo.com/>, 2026.
- [7] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [8] Pierre Geurts, Damien Ernst, and Louis Wehenkel. Extremely randomized trees. *Machine Learning*, 63(1):3–42, 2006.
- [9] Jina AI. Jina reader. <https://r.jina.ai/>, 2026.
- [10] Vlad Krotov and Leiser Silva. Legality and ethics of web scraping. In *Twenty-fourth Americas Conference on Information Systems*, New Orleans, 2018.
- [11] Microsoft Playwright. Playwright python documentation. <https://playwright.dev/python/docs/intro>, 2026.
- [12] mobile.de. Insights api documentation. <https://services.sandbox.mobile.de/docs/insights-api.html>, 2026.
- [13] mobile.de. mobile.de search api documentation. <https://services.mobile.de/docs/search-api.html>, 2026.
- [14] mobile.de. Seller api documentation. <https://services.mobile.de/docs/seller-api.html>, 2026.
- [15] Karl Pearson. Notes on regression and inheritance in the case of two parents. *Proceedings of the Royal Society of London*, 58:240–242, 1895.
- [16] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg,

- Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Edouard Duchesnay. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [17] Render. Render web services documentation. <https://render.com/docs/web-services>, 2026.
- [18] Revista Biz. Creștere a pieței auto în 2024. cele mai vândute mărci de mașini noi și second hand. <https://www.revistabiz.ro/crestere-a-pieteii-auto-in-2024-cele-mai-vandute-marci-de-masini-noi-si-second-hand/>, 2025.
- [19] Sherwin Rosen. Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy*, 82(1):34–55, 1974.
- [20] scikit-learn. Metrics and scoring documentation. https://scikit-learn.org/stable/modules/model_evaluation.html, 2026.
- [21] Colin Shearer. The crisp-dm model: The new blueprint for data mining. *Journal of Data Warehousing*, 5(4):13–22, 2000.
- [22] Alex J. Smola and Bernhard Schölkopf. A tutorial on support vector regression. *Statistics and Computing*, 14(3):199–222, 2004.
- [23] Nikiforos Zacharof, Jamil Nur, Dimitrios Kourtesis, Jette Krause, and Georgios Fontaras. A review of the used car market in the european union. Technical report, European Commission, Joint Research Centre, 2025.